

Diagnóstico de calidad de red

Manual de usuario del sistema de priorización de sitios. Escrito para el equipo de operaciones de red, no para programadores.

Repositorio: **diagnostico-calidad-red** Cadencia: **mensual** Audiencia: **analista / responsable de operaciones**

1 Para quién es este manual

Este manual está escrito para la persona que va a usar el resultado del sistema día a día: un analista o responsable de operaciones de red, no un programador. No hace falta saber programar ni entender de modelos estadísticos para seguir estos pasos ni para leer el resultado. Donde aparece un término técnico inevitable, se explica en palabras simples la primera vez que se usa (ver también el glosario, sección 9).

2 Qué hace el sistema, en una frase

El sistema revisa el historial de reclamos y los indicadores de calidad de la red, mes a mes, y entrega una lista ordenada de los sitios con mayor probabilidad de generar un reclamo próximamente, junto con el motivo probable y una recomendación de qué hacer con cada uno.

Es una herramienta de apoyo a la decisión, no reemplaza el criterio del equipo de red. El resultado ayuda a priorizar dónde mirar primero, no da una verdad absoluta.

3 Prerrequisitos técnicos

Esta parte la resuelve una sola vez la persona de TI o de datos que deja el ambiente listo. El usuario final no necesita repetirla cada vez.

Software necesario

Requisito	Detalle
Python	Versión 3.11 o superior
Gestor de paquetes	uv (recomendado) o pip
Librerías de Python	pandas, numpy, scikit-learn, xgboost, optuna, shap, matplotlib, seaborn, openpyxl, pyarrow. Se instalan solas al correr uv sync , no una por una.

Acceso a los datos	Archivos crudos en <code>db_files/</code> , o credenciales MySQL si se usa esa fuente
--------------------	---

Estructura de carpetas que espera el sistema

`diagnostico-calidad-red/`

```
src/           código del pipeline (construcción de datos, scoring)
dashboard/     tablero interactivo (app.py)
scripts/       utilidades, incluye la anonimización (sección 4)
notebooks/     notebooks de análisis y exploración
db_files/      entrada: archivos crudos
output/        salida: resultados generados
  modeling_dataset_monthly.parquet
mensual-pronopro/
  ranking_sitios.csv
  ranking_sitios.parquet
figures/
```

`db_files/` y `output/` no viajan con el código en el repositorio (datos del cliente y resultados derivados): se crean localmente al ejecutar los pasos de este manual.

4 Antes de empezar: los datos deben anonimizarse

Los archivos usados para el entrenamiento de los modelos datos personales (nombres, cédulas, teléfonos, correos) que aparecen tanto en columnas específicas como escritos dentro de la descripción libre de cada ticket. Este paso es obligatorio y se hace una sola vez por cada entrega de datos nueva, no cada vez que se genera un ranking.

Paso 0. Anonimizar los datos crudos

```
$ python scripts/cleanup-data.py
```

Lee `db_files/claims.xlsx` y genera una copia limpia en `output/claims_clean.csv`, reemplazando nombres, cédulas, teléfonos y correos por códigos. Los códigos son consistentes: la misma persona recibe el mismo código en todos sus reclamos, así el análisis no pierde la capacidad de relacionar información, solo la identidad real de la persona.

LIMITACIÓN CONOCIDA

Este paso automático cubre los casos más comunes, pero cuando el texto libre del ticket menciona a alguien de forma poco habitual o con errores de tipeo, puede no detectarlo. Por lo que se requiere una intervención manual.

```
$ python scripts/cleanup-data.py
```

```
Processed rows: 3  
Wrote cleaned CSV to: output/claims_clean.csv
```

5 Caso de uso típico: generar el ranking mensual

Con los datos ya anonimizados, generar el ranking de sitios toma dos pasos.

Paso 1. Construir el dataset del mes

```
$ python src/build_modeling_dataset.py --grain monthly --source files
```

Junta reclamos, ubicación de sitios e indicadores de red en una sola tabla, un registro por sitio y por mes. Guarda el resultado en output/modeling_dataset_monthly.parquet. Toma pocos minutos.

Paso 2. Generar el ranking de sitios en riesgo

```
$ python src/score_sites.py
```

Entrena el modelo con la información más reciente y calcula, para cada sitio, qué tan probable es que genere un reclamo. El resultado queda en dos archivos con la misma información: ranking_sitios.csv (para Excel/Sheets) y ranking_sitios.parquet (formato técnico).

```
...  
$ python src/score_sites.py  
  
df_monthly cargado: (15382, 15)  
Positivos (es_reclamo_confirmado_mensual): 647 / 15382 = 4.23%  
Train: (8931, 7) | positivos=588 (5.69%)  
Test: (4661, 7) | positivos=123 (2.64%)  
scale_pos_weight = 16.6  
Optuna best AUC-PR (CV interno): 0.8864  
Best params XGBosuit: {'n_estimators': 259, 'max_depth': 2, 'learning_rate': 0.816501479585938235, 'subsample': 0.8258921618124521, 'colsample_bytree': 0.9549718879994684, 'min_child_weight': 7, 'scale_pos_weight': np.float64(16.58878661417322), 'random_state': 42, 'eval_metric': 'aucpr'}  
AUC-PR (test): 0.8424  
...  
Ranking guardado: output/mensual-pronopra/ranking_sitios.parquet  
Ranking guardado (CSV, lectura manual): output/mensual-pronopra/ranking_sitios.csv  
Total sitios en ranking: 2335  
  
Top 10 sitios de mayor riesgo:  
site_id score_riesgo prioridad_sitio kpis_driver umbral_incumplido accion_recomendada cluster perfil meses_en_riesgo  
1485 0.604511 Alta USERS_4g, degradacion_THP_30d ninguno Inversión tecnológica 0 Estable 1  
723 0.603447 Alta USERS_4g, degradacion_THP_30d THP Inversión tecnológica 0 Congestión de capacidad 1  
743 0.603084 Alta USERS_4g, degradacion_THP_30d ninguno Inversión tecnológica 0 Congestión de capacidad 0  
959 0.602968 Alta USERS_4g, degradacion_THP_30d THP Inversión tecnológica 0 Congestión de capacidad 0  
1388 0.602431 Alta degradacion_THP_30d, USERS_4g ninguno Inversión tecnológica 0 Congestión de capacidad 2  
1843 0.605474 Alta USERS_4g, degradacion_THP_30d THP Inversión tecnológica 0 Congestión de capacidad 0  
182 0.602112 Alta USERS_4g, degradacion_THP_30d THP Inversión tecnológica 0 Congestión de capacidad 1
```

Salida real de score_sites.py: resumen de los 10 sitios de mayor riesgo

site_id	score_riesgo	prioridad_sitio	accion_recomendada	perfil
1485	0.665	Alta	Inversión tecnológica	Estable
733	0.659	Alta	Inversión tecnológica	Congestión de capacidad
743	0.659	Alta	Inversión tecnológica	Congestión de capacidad
959	0.658	Alta	Inversión tecnológica	Congestión de capacidad
1388	0.656	Alta	Inversión tecnológica	Congestión de capacidad
1043	0.655	Alta	Inversión tecnológica	Congestión de capacidad
102	0.652	Alta	Inversión tecnológica	Congestión de capacidad
253	0.652	Alta	Inversión tecnológica	Congestión de capacidad
1400	0.651	Alta	Inversión tecnológica	Estable
1559	0.651	Alta	Inversión tecnológica	Congestión de capacidad
1437	0.649	Alta	Inversión tecnológica	Congestión de capacidad
1240	0.649	Alta	Inversión tecnológica	Congestión de capacidad

Columnas principales de ranking_sitios.csv, datos reales de la corrida más reciente

CADENCIA DE USO

El sistema está pensado para correrse una vez al mes, después de que cierra el mes de datos. No hace falta correrlo con más frecuencia porque el histórico de reclamos que usa se actualiza a ese ritmo.

6 Cómo leer ranking_sitios.csv

El archivo trae un registro por cada sitio, ordenado del mayor riesgo al menor.

prioridad_sitio: ALTA MEDIA BAJA

Columna	Qué significa
site_id	Identificador del sitio (antena o estación de red)
score_riesgo	Probabilidad relativa de reclamo, escala 0 a 1. Mientras más alto, mayor prioridad
kpis_driver	Los dos indicadores de red que más empujan el resultado
umbral_incumplido	Qué reglas de negocio conocidas incumple el sitio
accion_recomendada	Inversión tecnológica / Mantenimiento programado / Monitoreo
cluster / perfil	Grupo de sitios con características parecidas, con etiqueta descriptiva
meses_en_riesgo	Cuántos meses del historial este sitio ya generó reclamo


IMPORTANTE

score_riesgo es una probabilidad relativa para comparar sitios entre sí, no un porcentaje de certeza absoluta. Un sitio con score 0.65 no significa 65% de certeza de que va a fallar: significa que está entre los sitios con más señales de riesgo comparado con el resto.

7 Cómo interpretar los gráficos de apoyo


Estos gráficos los genera el notebook de análisis, no el script de uso diario, y sirven para entender el porqué detrás del ranking. Quedan guardados en `output/mensual-pronopro/figures/`.

Importancia de cada indicador




Peso promedio de cada indicador en la decisión del modelo

Dirección del efecto






Si valores altos o bajos de cada indicador empujan el riesgo hacia arriba o abajo

Grupos de sitios



Sitios agrupados por perfil de comportamiento similar

Tasa de reclamo por umbral de indicador



Comparan, para cada indicador, cuántos reclamos hay por encima o por debajo del umbral de referencia. Es la evidencia detrás de los umbrales de negocio usados en el resto del sistema.

8 Incidencias habituales

Problema	Causa probable	Qué hacer
"Parquet no encontrado" al correr score_sites.py	No se corrió el Paso 1 antes	Correr build_modeling_dataset.py primero
Anonimización dice "Expected file not found"	No existe db_files/claims.xlsx, o tiene otro nombre	Confirmar que el archivo exista en esa ruta exacta
El ranking sale con muy pocos sitios o vacío	El dataset tiene menos de un mes completo de historia	Comportamiento esperado: se excluyen automáticamente
El comando tarda varios minutos	Ajuste automático de parámetros del modelo (Optuna)	Esperado, no interrumpir
Dudas sobre si un score_riesgo es confiable	Ver limitaciones del modelo	Revisar la sección de limitaciones antes de decidir

9 Glosario

Término	Qué significa
Sitio	Antena o estación de la red móvil
Reclamo	Queja del cliente registrada en el sistema de atención de Tigo Ecuador (ticket)
KPI / indicador de red	Medida técnica de la calidad de servicio de un sitio, por ejemplo disponibilidad o velocidad
Disponibilidad (AVA_4G)	Porcentaje de tiempo que el sitio estuvo operativo, sin cortes
Velocidad (THROUGHPUT_4G)	Velocidad de transferencia de datos que entrega el sitio, medida en Mbps
Score de riesgo	Número entre 0 y 1 que estima qué tan probable es que un sitio genere un reclamo próximamente
Driver	El indicador de red que más explica por qué un sitio tiene el score de riesgo que tiene

Umbral	Valor de referencia de negocio que, al incumplirse, señala un problema
Cluster / perfil	Grupo de sitios con comportamiento similar, con una etiqueta que describe ese comportamiento
Ranking	Lista de sitios ordenada de mayor a menor riesgo
Modelo	Programa que aprende patrones de los datos históricos para estimar el score de riesgo (en este proyecto, XGBoost)
Anonimización	Proceso de quitar o reemplazar datos personales antes de analizar la información